

Natural Language Processing Dr. Mohammad Bidoki Homework #4

آرین قره محمد زاده قشقایی

4017724001

محمد برزگر

4010724001

1- يىش يرداز

```
def import_text(name):
    with codecs.open(name, "r", encoding="cp1252") as f:
        text = f.read()
        return text
```

تابع import text برای وارد کردن فایل های تکست ترین و تست

```
def extract_sentence(text):
    text = text.replace("Mr.", "Mr<period>")
    text = text.replace("Jr.", "Jr<period>")
    text = text.replace("Ms.", "Ms<period>")
    text_tokens = sent_tokenize(text, "english")
    text_tokens = [sentence.replace("Jr<period>", "Jr.") for sentence in text_tokens]
    text_tokens = [sentence.replace("Mrs<period>", "Mrs.") for sentence in text_tokens]
    text_tokens = [sentence.replace("Mr<period>", "Mrs.") for sentence in text_tokens]
    return text_tokens
```

این تابع برای جدا سازی جملات استفاده میشود. مشکلی که در فایل های تکست وجود داشت. این بود که موقع توکنایز کردن جملات زمانی که به کلمات .MR. MSS. Jr می رسید به دلیل داشتن نقطه جمله را توکنایز میکرد برای جلوگیری از این کار ابتدا نقطه بعد این کلمات را حذف و بعد از توکنایز کردن به آن اضاف کردیم.

```
def removing(senteces_token):
    patternEng = r'[a-zA-Z0-9]+'
    RegtokenizerEng = RegexpTokenizer(patternEng)
    result = []
    for sentence in senteces_token:
        noPunctuationtokens = RegtokenizerEng.tokenize(sentence)
        sentence = ' '.join(noPunctuationtokens)
        result.append(sentence)
    return result
```

این تابع برای حذف اعداد و حروف نگارشی توکن های حاوی جملات استفاده شده.

2- ساختن مدل زباني

```
def Myngram(tokens, n):
   tokens = nltk.word_tokenize(tokens)
   n_grams = list(ngrams(tokens, n))
   return n_grams
```

این تابع برای ساخت n گرام ها در نظر گرفته شده.

```
def calculateUniprobability(sentences):
    gram1 = []
    for i in sentences:
        gram1.extend(Myngram(i, 1))
    counter = Counter(gram1)
    gramNumber = sum(counter.values())
    probability = {}
    for key, values in counter.items():
        probability[key] = values / gramNumber
    return probability, counter
```

تابع فوق برای محاسبه احتمال کلمات به صورت یونیگرام در نظر گرفته شده، که ورودی آن جملات هستند و خروجی آن دو دیکشنری. اولی: دیکشنری برای در نظر گرفتن کلمات یونیک و تعداد آن ها و دیکشنری دومی برای نگه داری احتمال آن ها در نظر گرفته شده.

```
def calculateBigramProbability(sentences):
    gram2 = []
    for i in sentences:
        gram2.extend(Myngram(i, 2))
    counter = Counter(gram2)
    bigram_probabilities = {}
    for (prev_word, curr_word), count in counter.items():
        if prev_word not in bigram_probabilities:
            bigram_probabilities[prev_word] = {}

        total_count = sum(counter.values())
        probability = count / total_count
        bigram_probabilities[prev_word][curr_word] = probability
    return bigram_probabilities
```

این تابع برای محاسبه احتمال bi گرام در نظر گرفته شده. که ورودی آن جملات هست و خروجی آن value که خروجی آن مشابه زیر میشود.

که میتوان با قطعه کد زیر یک جمله را جنریت کرد

```
in[8]: generatedsentence = []
initial theWord = "I"
initial range(20):
initial range
```

مشكلي كه بايگرام داره:

```
In[17]: generatedsentence = []
....: theWord = "name"
....: for i in range(20):
....: theWord = get_probable_next_word_bigram(BigramProbability, theWord)
....: generatedsentence.append(theWord)
....: print(generatedsentence)
['of', 'the', 'same', 'time', 'to', 'the', 'same', 'time', 'to', 'the', 'same', 'time', 'to', 'the', 'same', 'time']
```

تو کلماتی مثل and, the, a یه پترن خاص تکرار میشه مشابه این تابع تری گرام نیز ساخته میشود.

ولی این تابع به دلیل اینکه تایم زیادی برای پردازش نیاز داشت نتوانستیم خروجی آن را پیدا کنیم. ولی با یک corpus کوچک تر که امتحان کردیم کاملا تابع درست عمل میکرد.

پس برای رفع این مشکل از تابع زیر آمدیم استفاده کردیم که به کمک bigram ساخته شده

```
def calculateThreegramProbability(sentences):
    gram3 = []
    gram2 = []

for i in sentences:
        gram3.extend(Myngram(i, 3))
        gram2.extend(Myngram(i, 2))
    counter3 = Counter(gram3)
    counter2 = Counter(gram2)
    threegram_probabilities = {}
    for (prev_prev_word, prev_word, curr_word), count in counter3.items():
        if (prev_prev_word, prev_word) not in threegram_probabilities:
            threegram_probabilities[(prev_prev_word, prev_word)] = {}
        bigram_count = counter2[(prev_prev_word, prev_word)]
        probability = count / bigram_count
        threegram_probabilities[(prev_prev_word, prev_word)][curr_word] = probability
    return threegram_probabilities
```

جنريت جمله:

بایگرام

```
def generate_unigram_sentence(range,theWord):
    generatedsentence = [theWord]
    for i in range(range):
        theWord = get_probable_next_word_bigram(BigramProbability, theWord)
        generatedsentence.append(theWord)
```

تریگرام:

```
def generate_treegram_sentence(range,theWord,secWord,TreegramProbability):
    generatedsentence = [theWord_secWord]
    theWord = "I"
    secWord = "was"
    for i in range(20):
        generated = get_probable_next_word_threegram(TreegramProbability, theWord, secWord)
        generatedsentence.append(generated)
        theWord = secWord
        secWord = generated
    return__generatedsentence
```

که کاملا بهتر از مدلbigram عمل میکنه ولی همچنان ممکن است وارد لوپ کلمات شود. همینطور این احتمالات با تکنیک های laplace smoothing و good-turing smoothing نیز انجام شده.

این متد ها کمک میکند که داده های آنسین ما که در مدل ترین شده ما قرار ندارند مقدار 0 را نگیرند و یه احتمالی نیز برای آن ها در نظر گرفته بشه.

```
def calculateLaplaceSmothing(sentences):
    gram3 = []
    for i in sentences:
        gram3.extend(Myngram(i, 1))
    counter = Counter(gram3)
    Unique_V = len(counter)
    Total_numberOfWords = sum(counter.values())
    LS = {}
    for key, values in counter.items():
        LS[key] = (values + 1) / (Total_numberOfWords + Unique_V)
    return LS, Total_numberOfWords
```

برای بیگرام:

```
def calculategood_smoothingBigramProbability(sentences):
   bigram_counts = Counter()
      bigram_counts.update(bigrams)
       unigram_counts.update(words)
   observed_counts = Counter(bigram_counts.values())
   total_bigrams = sum(bigram_counts.values())
   total_unigrams = sum(unigram_counts.values())
   r_star = (np.arange(1, max(observed_counts)) + 1) * (observed_frequencies[1:] / observed_frequencies[:-1])
   c_star = r_star - observed_counts[1:]
   c_star[0] = 1 # Adjust for unseen bigrams
   bigram_probabilities = {}
   for bigram, count in bigram_counts.items():
       prev_word = bigram[0]
       probability = (count + c_star[count]) / (total_unigrams + c_star[1])
       if prev_word not in bigram_probabilities:
           bigram_probabilities[prev_word] = {}
       bigram_probabilities[prev_word][bigram[1]] = probability
```

اینگونه کلماتی که تعداد 0 دارند با اضاف شدن 1 به آنها مقدار نهایی احتمال آن یک عدد غیر از صفر میشود.

در واقع هموار سازی good-turning بر اساس frequencies کلمات مشاهده شده n گرام های دیگر یک احتمال غیر از صفر به داده های دیده نشده میدهد.

در مقایسه با روش لاپلاس که یک توزیع یکنواختی را برای داده های دیده نشده در نظر میگیرد این روش روش بهتری هست چون ممکن هست تعداد کلمات دیده نشده مقدار خیلی زیادی باشند که احتمال مشابهی میگیرند اینگونه با این روش (good turing) مقادیر مختلفی به این کلمات نسبت داده میشود.

توابع زیر نیز برای بدست آوردن perplexity ساخته شده اند.

```
def calculate_perplexity(language_model, test_dataset, totalWords):
    total_log_prob = 0.0
    word_count = 0
    Unique_V = len(language_model)
    for token in test_dataset:
        if token in language_model:
            word_prob = language_model[token]
        else:
            word_prob = 1 / (Unique_V + totalWords)

        total_log_prob += math.log(word_prob)
        word_count += 1

avg_log_prob = total_log_prob / word_count
    perplexity = math.exp(-avg_log_prob)
    return perplexity
```

```
def calculate_perplexity_bigram(sentences, bigram_probabilities):
    total_log_probability = 0.0
    total_words = 0
    for sentence in sentences:
        words = sentence.split()
        total_words += len(words)
        for i in range(1, len(words)):
            prev_word = words[i-1]
            curr_word = words[i]
        # Check if bigram exists in the probabilities dictionary
        if prev_word in bigram_probabilities and curr_word in bigram_probabilities[prev_word]:
            bigram_probability = bigram_probabilities[prev_word][curr_word]
        else:
            # Handle unseen bigrams by assigning a very small probability
            bigram_probability = 1e-10
            total_log_probability += math.log2(bigram_probability)
        average_log_probability = total_log_probability / total_words
        perplexity = 2 ** (-average_log_probability)
        return perplexity
```

استفاده از توابع فوق برای یونیگرام:

```
# Preprocessing

text = import_text("brown.train.txt")

test = import_text("brown.test.txt")

sentence = extract_sentence(text)

sentenceTest = extract_sentence(test)

result = removing(sentence)

resultTest = removing(sentenceTest)

testTokens = removepunctation(test)

# unigram

Uniprobability , UniqueWords = calculateUniprobability(result)

laplaceSmothing_Total_numberOfWords = calculateLaplaceSmothing(result)

perplexity = calculate_perplexity(laplaceSmothing_testTokens_Total_numberOfWords)

theWord = get_probable_next_word(laplaceSmothing_("if",))

unigram_goodturing , uni_unseen_gt = calculate_good_turing_unigram_probability(result)
```

استفاده از توابع فوق برای بایگرام:

```
# bigram
corpus = "I am learning language proccessing and I am happy."
corpus = extract_sentence(corpus)
corpus = removing(corpus)
BigramProbability = calculateBigramProbability(result)
print(BigramProbability)
theWord = get_probable_next_word_bigram(BigramProbability_"I")
print(theWord)

bigram_laplace, bigram_Total_numberOfWords = calculateLaplaceSmothing(result)
bigram_perplexity = calculate_perplexity_bigram(result, BigramProbability)
bigram_goodturing, unseen_p = calculategood_smoothingBigramProbability(result)
```

تولید کردن جمله ها:

```
# generate sentence
sentence_uni_one = generate_uni_sentence(20, 'I', 'was', Uniprobability)
sentence_uni_two = generate_uni_sentence(20, 'Jury', 'said', Uniprobability)
sentence_uni_three = generate_uni_sentence(20, 'The', 'jury', Uniprobability)
sentence_uni_four = generate_uni_sentence(20, 'These', 'actions', Uniprobability)
sentence_uni_five = generate_uni_sentence(20, 'Four', 'additional', Uniprobability)
sentence_uni = [sentence_uni_one, sentence_uni_two, sentence_uni_three, sentence_uni_four, sentence_uni_five]

sentence_bi_one = generate_bigram_sentence(20, 'I', 'was', BigramProbability)
sentence_bi_two = generate_bigram_sentence(20, 'Jury', 'said', BigramProbability)
sentence_bi_three = generate_bigram_sentence(20, 'These', 'jury', BigramProbability)
sentence_bi_four = generate_bigram_sentence(20, 'These', 'actions', BigramProbability)
sentence_bi_five = generate_bigram_sentence(20, 'Four', 'additional', BigramProbability)
sentence_bi = [sentence_bi_one, sentence_bi_two, sentence_bi_three_sentence_bi_four_sentence_bi_five]
```

محاسبه perplexity جملات و مدل ها:

```
uni_pp_mle = []
uni_pp_laplace = []
uni_pp_good = []
bi_pp_mle = []
bi_pp_laplace = []
bi_pp_good = []
for i in range(len(sentence_uni)):
    uni_pp_mle.append(calculate_perplexity(Uniprobability, sentence_uni[i]))
    uni_pp_laplace.append(calculate_perplexity(laplaceSmothing, sentence_uni[i]))
    uni_pp_good.append(calculate_perplexity(unigram_goodturing, sentence_uni[i]))
for i in range(len(sentence_bi)):
    bi_pp_mle.append(calculate_perplexity_bigram(sentence_bi[i], BigramProbability))
    bi_pp_laplace.append(calculate_perplexity_bigram(sentence_bi[i], bigram_laplace))
    bi_pp_good.append(calculate_perplexity_bigram(sentence_bi[i], bigram_goodturing))
uni_perplexity_mle = calculate_perplexity(Uniprobability, test)
uni_perplexity_laplace = calculate_perplexity(laplaceSmothing, test)
uni_perplexity_good = calculate_perplexity(unigram_goodturing, test)
bi_perplexity_mle = calculate_perplexity_bigram(test, BigramProbability)
bi_perplexity_laplace = calculate_perplexity_bigram(test, bigram_laplace)
bi_perplexity_good = calculate_perplexity_bigram(test, bigram_goodturing)
```

جملات ساخته شده با یونیگرام:

جملات ساخته شده با بایگرام:

```
bisentence_generate.txt X +

File Edit View

['I', 'was', 'a', 'few', 'years', 'ago', 'the', 'same', 'time', 'to', 'the', 'same', 'time', 'to', 'the', 'same', 'time', 'to']
['Jury', 'said', 'that', 'the', 'same', 'time', 'to', 'the', 'same', 'time'
```

مقدار perplexity جملات یونیگرام به ترتیب به شکل زیر است:

لیست اول مربوط یه گود تورینگ، دوم لایلاس و سوم mle است:

```
✓ ⅓ uni_pp_good = {list: 5} [5358867312.681481, 3196400489.0384645, 2719791234.108872, 1316981795.9787066, 1423953170.3285275]
      01 0 = {float} 5358867312.681481
      01 1 = {float} 3196400489.0384645
      01 2 = {float} 2719791234.108872
      01 3 = {float} 1316981795.9787066
      01 4 = {float} 1423953170.3285275
   > Protected Attributes
      0 = {float} 4814.581703501139
      1 = {float} 7848.191789519194
      01 2 = {float} 8191.896729437103
      3 = {float} 4837.397164015461
      01 4 = {float} 16195.436251089333
   > Protected Attributes

    \[
    \frac{1}{2} \] uni_pp_mle = \[
    \left\] [4683.591957049676, 7763.511945878278, 8208.276232029604, 4770.316750232196, 16643.90738986477]

      01 0 = {float} 4683.591957049676
      01 1 = {float} 7763.511945878278
      01 2 = {float} 8208.276232029604
      3 = {float} 4770.316750232196
      01 4 = {float} 16643.90738986477
```

احتمال بایگرام گود تورینگ، لایلاس و mle بایگرام ها:

```
oi bi_perplexity_good = {float} 1.0
oi bi_perplexity_laplace = {float} 1.0
oi bi_perplexity_mle = {float} 1.0
```

احتمال mle بایگرام در فایل bigram_probabilities.txt هست و تعداد آن 42321 است:

احتمال لاپلاس بایگرام در فایل bigram_laplace.txt هست و تعداد ان 44230؛

احتمال گود تورینگ بایگرام به شکل زیر است و در فایل bigram_goodturing.txt است:

احتمال mle یونیگرام به شکل زیر است و در فایل unigram_probabilities.txt است: تعداد 44230

```
### Land Company | File | Edit | View | File | File
```

احتمال لاپلاس يونيگرام به شكل زير است و تعداد آن 44230 و در فايل unigram_laplace:



تودتورینگ یونیگرام در فایل unigram_goodturing.txt:



مقدار perplexity برای مدل های بایگرام به شکل زیر است:

```
    bi_perplexity_good = {float} 1.0
    bi_perplexity_laplace = {float} 1.0
    bi_perplexity_mle = {float} 1.0
```

مقدار perplexity برای مدل های یونیگرام به شکل زیر است:

```
uni_perplexity_good = {float} 7835780.118023064
uni_perplexity_laplace = {float} 4999999998.992869
uni_perplexity_mle = {float} 4999999998.992869
```

مقدار perplexity برای جملات در بالا گزارش شده.