

Natural Language Processing Dr. Mohammad Bidoki

Homework #3

By: Mohammad Barzegar

Student ID: 4010724001

تمرین a (توکنایز و حذف علامت های اضافی):

ابتدا با استفاده از WhiteSpaceTokenizer، اسپیس ها و تب ها و لاین بریک ها را پاک کرده تا فایل یکدست شود:

```
import nltk
import nltk.tokenize import WhitespaceTokenizer

# Deleting spaces and tabs

input_filenames = ['sport.txt', 'tech.txt']

output_filenames = ['sport1.txt', 'tech1.txt']

for i in range(len(input_filenames)):

with open(input_filenames[i], "r") as f:
 input_text = f.read()

# Tokenize the text using WhiteSpaceTokenizer
tokenizer = WhitespaceTokenizer()
tokens = tokenizer.tokenize(input_text)
output_text = ' '.join(tokens)

# Save the tokens to an output text file
with open(output_filenames[i], "w") as f:
f.write(output_text)
```

تمرین b (حذف کردن stopword ها و حروف تک کاراکتری):

خروجي مرحله قبل، ورودي اين مرحله است. با استفاده از RegexpTokenizer همه ي كاراكتر ها بجز

حروف الفباى انگليسى را حذف مى كنيم:

```
# Delete all characters except alphabet letters

from nltk.tokenize import RegexpTokenizer

input_filenames = ['sport1.txt', 'tech1.txt']

output_filenames = ['sport2.txt', 'tech2.txt']

tokenizer = RegexpTokenizer(r'[a-zA-Z]+')

for i in range(len(input_filenames)):

with open(input_filenames[i], "r") as f:

input_text = f.read()

words = tokenizer.tokenize(input_text.lower())

# Save the tokens to an output text file

with open(output_filenames[i], "w") as f_out:

f_out.write(" ".join(words))
```

خروجی مرحله قبل را برداشته و سپس حروف تک کاراکتری را حذف می کنیم:

```
input_filenames = ['sport2.txt', 'tech2.txt']
output_filenames = ['sport3.txt', 'tech3.txt']

for i in range(len(input_filenames)):
    with open(input_filenames[i], 'r') as file:
        text = file.read()

# Split the text into words
words = text.split()

# Remove one-character words
words = [word for word in words if len(word) > 1]

# Join the remaining words back into a string
updated_text = ' '.join(words)

# Write the updated text back into the file
with open(output_filenames[i], 'w') as file:
file.write(updated_text)
```

با استفاده از خروجی مرحله قبل، حروف stopword را نیز حذف میکنیم:

```
# Removing stopwords

nltk.download('stopwords')

from nltk.corpus import stopwords

from nltk.tokenize import word_tokenize

input_filenames = ['sport3.txt', 'tech3.txt']

output_filenames = ['sport4.txt', 'tech4.txt']

stop_words = set(stopwords.words('english'))

stop_words = set(stopwords.words('english'))

with open(input_filenames)):

text = f.read()

words = word_tokenize(text)

cleaned_words = [word for word in words if word not in stop_words]

cleaned_text = ' '.join(cleaned_words)

with open(output_filenames[i], 'w') as f_out:

f_out.write(cleaned_text)

print(input_filenames[i], 'Before:', len(text), 'After:', len(cleaned_text))
```

sport3.txt Before: 908175 After: 638400
tech3.txt Before: 1141164 After: 817591

تمرین type) c های موجود در هر متن):

با استفاده از متد pos_tag، تایپ هر کلمه را برای هر فایل مشخص میکنیم. خروجی را در فایل word_type.txt می توانید مشاهیده بفرمایید.

```
## Word_type.txt X +

File Edit View

('sport4.txt', Counter({'NN': 34631, 'JJ': 17885, 'NNS': 8413, 'VBD': 6705, 'RB': 5100, 'VBP': 4453, 'VBG': 3435, 'VBN': 2356, 'VB': 1868, 'CD': 1783, 'IN': 1476, 'VBZ': 1409, 'MD': 817, 'JJS': 355, 'JJR': 276, 'DT': 247, 'PRP': 221, 'RBR': 206, 'FW': 183, 'NNP': 177, 'RP': 106, 'CC': 53, 'RBS': 25, 'WP$': 21, 'WRB': 12, 'WP': 12, 'WDT': 11, 'NNPS': 1, 'EX': 1, 'PDT': 1, 'TO': 1}))

('tech4.txt', Counter({'NN': 37840, 'JJ': 19992, 'NNS': 17672, 'VBP': 6476, 'VBD': 6189, 'RB': 5794, 'VBG': 5326, 'VBN': 3239, 'VBZ': 2415, 'VB': 2316, 'IN': 2019, 'CD': 1507, 'MD': 1215, 'JJR': 475, 'JJS': 426, 'PRP': 399, 'RBR': 300, 'DT': 230, 'NNP': 170, 'FW': 136, 'RP': 86, 'CC': 61, 'RBS': 18, 'WDT': 14, 'WP': 11, 'WP$': 6, 'WRB': 5, 'PRP$': 3, 'NNPS': 3, 'PDT': 2, 'POS': 1, 'UH': 1}))
```

تمرین d (تعداد کلمه football و computer):

تعداد تکرار هر کلمه در هر دو فایل را به دست می آوریم:

```
1 input_filenames = ['sport4.txt', 'tech4.txt']
2 football_count = {'sport': 0, 'tech': 0}
3 computer_count = {'sport': 0, 'tech': 0}
5 for i in range(len(input_filenames)):
       with open(input_filenames[i], 'r') as file:
           text = file.read()
       text = text.lower()
       football count['sport'] = text.count('football')
       computer count['tech'] = text.count('computer')
17 print("Occurrences of 'football':", football_count)
   print("Occurrences of 'computer':", computer_count)
    Occurrences of 'football': {'sport': 15, 'tech': 0}
    Occurrences of 'computer': {'sport': 0, 'tech': 444}
```

تعداد تكرار football در فايل football و در فايل tech بار است.

تعداد تکرار computer در فایل sport و در فایل computer بار است.

تمرین e (ماتریس term-document):

ابتدا تابعی مینویسیم که با گرفتن نام 2 فایل، ماتریس term-document را بسازد. از متد countervectorizer

```
from sklearn.feature_extraction.text import CountVectorizer
import numpy as np

def create_word_term_matrix(file1_path, file2_path):
    # Read the contents of the first file
    with open(file1_path, 'r') as file1:
        text1 = file1.read()

# Read the contents of the second file
with open(file2_path, 'r') as file2:
    text2 = file2.read()

# Combine the text from both files into a single list
combined_text = [text1, text2]

# Create an instance of CountVectorizer
vectorizer = CountVectorizer()

# Fit the vectorizer to the combined text and transform it into a word-term matrix
word_term_matrix = vectorizer.fit_transform(combined_text)

# Convert the matrix to a NumPy array
word_term_matrix = word_term_matrix.toarray()

# Get the feature names (words) from the vectorizer's vocabulary
words = vectorizer.get_feature_names_out()
return word_term_matrix, words
```

سپس با استفاده از این تابع، خروجی مورد نظر را در فایل word_term_matrix.txt ذخیره می کنیم که در فایل sport و المان دوم (راست) تعداد در فایل تحویلی موجود است. المان اول (چپ) تعداد کلمه در فایل tech است.

```
file1_path = 'sport4.txt'
file2_path = 'tech4.txt'
matrix, words = create_word_term_matrix(file1_path, file2_path)

# Print the word-term matrix
print("Word-Term Matrix:")

with open('word_term_matrix.txt', 'w') as file:
for i, word in enumerate(words):
    print(f"{word}: {matrix[:, i]}")
    file.write(f"{word}: {matrix[:, i]} \n")

# first element is word count in sport.xt and second element is count in tech.txt
```



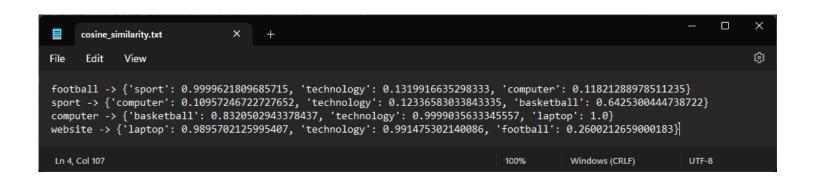
تمرین f (شباهت کسینوسی):

با استفاده از کتابخانه sklearn و متد های countervectorizer و cosine_similarity تابعی می سازیم تا شباهت کسینوسی را محاسبه کند:

```
from sklearn.feature_extraction.text import CountVectorizer from sklearn.metrics.pairwise import cosine_similarity
```

```
def calculate_cosine_similarity(file1_path, file2_path, word1, word2):
   with open(file1_path, 'r') as file1:
       text1 = file1.read()
   with open(file2_path, 'r') as file2:
       text2 = file2.read()
   text_list = [text1.lower(), text2.lower()]
   vectorizer = CountVectorizer()
   word_term_matrix = vectorizer.fit_transform(text_list)
   word_term_array = word_term_matrix.toarray()
   word1_index = vectorizer.vocabulary_.get(word1)
   word2_index = vectorizer.vocabulary_.get(word2)
   if word1_index is None or word2_index is None:
   word1_vector = word_term_array[:, word1_index]
   word2_vector = word_term_array[:, word2_index]
   word1_vector = word1_vector.reshape(1, -1)
   word2_vector = word2_vector.reshape(1, -1)
   similarity = cosine_similarity(word1_vector, word2_vector)[0, 0]
   return similarity
```

سپس با استفاده از تابع فوق، ورودی دو فایل تکست را داده و شباهت های کسینوسی مورد نظر را به عنوان خروجی در فایل cosine_similarity.txt که در فولدر تحویل داده موجود است، درج می کنیم.



كلمه مرجع	كلمات	شباهت كسينوسى
Football	<mark>Sport</mark>	0.9999621809685715
	Technology	0.1319916635298333
	Computer	0.1182128897851123
Sport	Computer	0.1095724672272765
	Technology	0.1233658303384333
	Basketball	0.6425300444738722
Computer	Basketball	0.8320502943378437
	Technology	0.9999035633345557
	<u>Laptop</u>	1.0
Website	Laptop	0.9895702125995407
	Technology	0.991475302140086
	Football	0.2600212659000183

همانگونه که نشان داده شده است، بیشترین شباهت کلمه football با کلمه ی sport، بیشترین شباهت کلمه website با کلمه ی laptop با computer و بیشترید شباهت basketball، و بیشترید شباهت technology با کلمه ی technology است.